pandas简介

Pandas 是 Python 进行数据分析的一个扩展库，是基于 NumPy 的一种工具。能够快速得从不同格式的文件中加载数据（比如 CSV 、Excel文件等），然后将其转换为可处理的对象。

Pandas 在 ndarray 的基础上构建出了两种更适用于数据分析的存储结构，分别是 Series（一维数据结构）和 DataFrame（二维数据结构）。在操作 Series 和 DataFrame 时，基本上可以看成是 NumPy 中的一维和二维数组来操作，数组的绝大多数操作它们都可以适用。

Pandas Series

- Series是一种一维数据结构，每一个元素都带有一个索引，与 NumPy 中的一维数组类似
- Series 可以保存任何数据类型，比如整数、字符串、浮点数、Python 对象等，它的索引默认为整数，从 0 开始依次递增。Series 的结构图，如下所示：

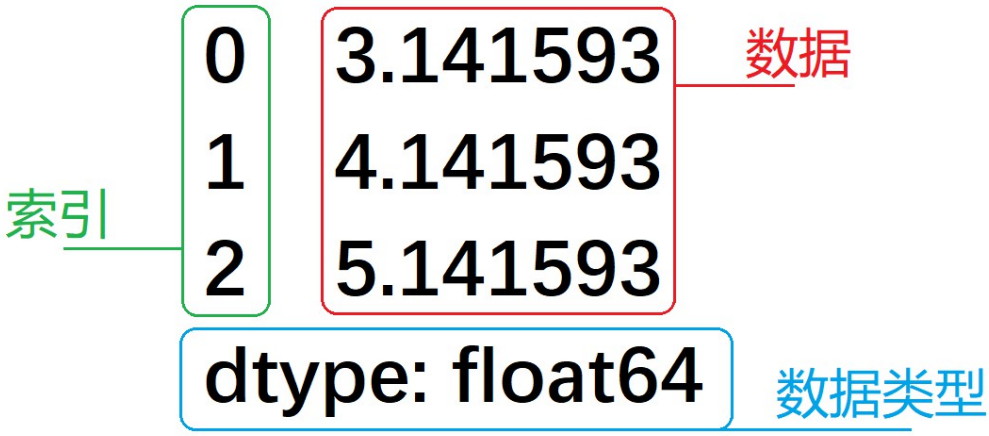

创建 **Series** 对象

pd.Series(data=None, index=None, dtype=None, name=None)

- data：array-like, dict, or scalar value
- index：索引必须是不可变数据类型，允许相同。不指定时，默认为从 0 开始依次递增的整数
- dtype：数据类型，如果没有指定，则会自动推断得出
- name：设置 Series 的名称

```
import numpy as np
import pandas as pd


""" 标量创建Series对象:
标量值按照 index 的数量进行重复，并与其一一对应
如果没有指定index, 就只有一个数据 """
d = 99
ser = pd.Series(data=d)
print(ser)
ser = pd.Series(data=d, index=[1, 2, 3])
```

```
print(ser)

""" str创建Series对象: 当作标量一样处理 """
d = 'abc'
ser = pd.Series(data=d, index=[1, 2, 3])
print(ser)

""" list创建Series对象 """
d = ['a', 'b', 'c']
ser = pd.Series(data=d)
print(ser)

""" ndarray创建Series对象 """
d = np.array([1, 2, 3])
ser = pd.Series(data=d, dtype=np.float64, index=
('one', 'two', 'three'), name='test-series')
print(ser)

""" dict创建Series对象:
默认用字典的键作为index, 对应字典的值作为数据 """
d = {'a': 1, 'b': 2, 'c': 3}
ser = pd.Series(data=d)  # index=['a', 'b', 'c'] 可省略
print(ser)

""" dict创建Series对象:
如果指定索引不是字典的键, 那么会得到缺失值NaN """
d = {'a': 1, 'b': 2, 'c': 3}
ser = pd.Series(data=d, index=['a', 'y', 'z'])
print(ser)
```

访问 **Series** 数据

两种方式：位置索引访问、索引标签访问

- 位置索引访问

```
import numpy as np
import pandas as pd


d = np.array([1, 2, 3, 4, 5])
ser = pd.Series(data=d, index=('a', 'e', 'c', 'd',
'e'))
print(ser)
print(ser[1])
print(ser[1:3])
print(ser[:-2:2])
print(ser[[2, 1, 3]])
```

- 索引标签访问

```
import numpy as np
import pandas as pd


d = np.array([1, 2, 3, 4, 5])
ser = pd.Series(data=d, index=('a', 'e', 'c', 'd',
'e'))
print(ser)
print(ser['c'])
print(ser['e'])

""" 索引标签切片时，右边不是开区间哦 """
```

```
print(ser['a':'d'])  # ser['e':'d']报错，因为'e'不唯一
print(ser[:'c':2])
print(ser[['c', 'e', 'd']])
```

修改 **Series** 索引

- 可以通过给 index 属性重新赋值达到修改索引的目的

```
import pandas as pd


ser = pd.Series([4, 7, -5, 3], index=['a', 'b', 'c',
'd'])
print(ser)
ser.index = ['aa', 'bb', 'cc', 'dd']  # 修改原数据
print(ser)
```

修改 **Series** 数据

- 可以通过索引和切片的方式修改数据

```
import pandas as pd


ser = pd.Series([2, 3, 4, 5], index=['a', 'b', 'c',
'd'])
ser['a'] = 8
print(ser)
ser['b':'d'] = [7, 8, 9]
print(ser)
```

Series 常用属性

属性	描述
dtype	返回 Series 对象数据类型
name	返回 Series 对象名称
shape	返回 Series 对象的形状
size	返回 Series 中的元素数量
values	以 ndarray 数组的形式返回 Series 中的数据
index	返回 index

```
import pandas as pd


d = [1, 2, 3, 4]
ser = pd.Series(data=d, index=['a', 'b', 'c', 'd'],
name="Test-Series")
print(ser.dtype)
print(ser.name)
print(ser.size)
print(ser.values)
print(ser.index)
```

Series 运算

Series 保留了 NumPy 中的数组运算，且 Series 进行数组运算的时候，索引与值之间的映射关系不会发生改变。在进行 Series 和 Series 的运算时，把两个 Series 中索引一样的值进行运算，其他不一样的做并集，对应的值为 NaN

```
import pandas as pd



ser1 = pd.Series([15, 20], index=["a", "b"])
print(ser1 + 1)
print(ser1 - 1)
print(ser1 * 2)
print(ser1 / 2)

ser2 = pd.Series([1, 2], index=["c", "a"])
print(ser1 + ser2)
print(ser1 - ser2)
print(ser1 * ser2)
print(ser1 / ser2)
```

Pandas DataFrame

DataFrame 是一种表格型的二维数据结构，既有行索引（index），又有列索引（columns），且默认都是从0开始递增的整数。可以把每一列看作是共同用一个索引的 Series，且不同列的数据类型可以不同。DataFrame 的结构图，如下所示：

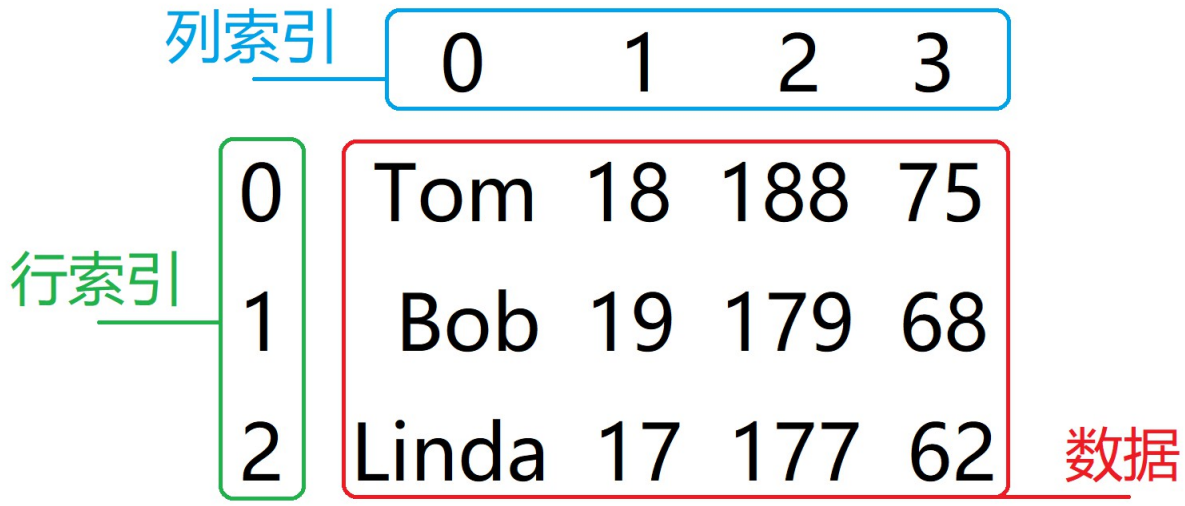

创建 **DataFrame** 对象

pd.DataFrame(data=None, index=None, columns=None, dtype=None)

- data：array-like, dict
- index：行索引。不指定时，默认为从 0 开始依次递增的整数
- columns：列索引。不指定时，默认为从 0 开始依次递增的整数
- dtype：数据类型，如果没有指定，则会自动推断得出

```
import numpy as np
import pandas as pd



""" ndarray创建DataFrame对象 """
d = np.array([[1, 2, 3], [4, 5, 6]])
df = pd.DataFrame(data=d, dtype=np.float64)
```

```
print(df)

""" 单一列表创建DataFrame对象 """
d = ['Tom', 'Bob', 'Linda']
df = pd.DataFrame(data=d)
print(df)

""" 嵌套列表创建DataFrame对象 """
d = [['Tom', 17], ['Bob', 18], ['Linda', 26]]
df = pd.DataFrame(data=d, index=['p1', 'p2', 'p3'],
columns=['name', 'age'])
print(df)

""" 字典嵌套列表创建DataFrame对象:
字典data中，所有键对应的值的元素个数必须相同
默认情况下，字典的键被用作列索引 """
d = {'name': ['Tom', 'Bob', 'Linda'], 'age': [17, 18,
26]}
df = pd.DataFrame(data=d, index=['p1', 'p2', 'p3'])
print(df)

""" Series创建DataFrame对象 """
d = {'name': pd.Series(['Tom', 'Bob', 'Linda'], index=
['p1', 'p2', 'p3']), 'age': pd.Series([17, 18, 26],
index=['p1', 'p2', 'p8'])}
df = pd.DataFrame(data=d)
print(df)

d = [pd.Series(['Tom', 'Bob', 'Linda'], index=['p1',
'p2', 'p3'], name="name"), pd.Series([17, 18, 26],
index=['p1', 'p2', 'p3'], name='age')]
df = pd.DataFrame(data=d)
print(df)
```

访问 **DataFrame** 数据

- 索引获取列数据，切片获取行数据

```
import pandas as pd


d = {'name': ['Tom', 'Bob', 'Linda'], 'age': [17, 18,
26], 'height': [172, 176, 188]}
df = pd.DataFrame(data=d, index=['p1', 'p2', 'p3'])
print(df)

# 索引获取列数据
print(df['age'])
print(df[['age', 'name']])

# 切片获取行数据
print(df[0: 1])  # 下标切片左闭右开
print(df['p1': 'p2'])  # 标签切片两边都是闭区间

# 组合使用
print(df[['name', 'age']][0: : 2])
print(df[0: : 2][['name', 'age']])
```

- loc指定标签获取数据，iloc指定下标获取数据

```
import pandas as pd


d = {'name': ['Tom', 'Bob', 'Linda'], 'age': [17, 18,
26], 'height': [172, 176, 188]}
df = pd.DataFrame(data=d, index=['p1', 'p2', 'p3'])
print(df)
```

```
""" loc允许接两个参数分别是行和列，且只能接收标签索引 """
# 选取行索引为'p1'的数据
print(df.loc['p1'])

# 选取行索引为'p2'且列索引为'age'的数据
print(df.loc['p2', 'age'])

# 选取行索引为'p2'且列索引分别为'age'和'name'的数据
print(df.loc['p2', ['age', 'name']])

# 选取行索引分别为'p3'和'p2'且列索引分别为'age'和'name'的数据
print(df.loc[['p3', 'p2'], ['age', 'name']])



""" iloc允许接两个参数分别是行和列，且只能接收整数索引 """
# 选取行索引为0的数据
print(df.iloc[0])

# 选取行索引为1且列索引为1的数据
print(df.iloc[1, 1])

# 选取行索引为1且列索引分别为1和0的数据
print(df.iloc[1, [1, 0]])

# 选取行索引分别为2和1且列索引分别为1和0的数据
print(df.iloc[[2, 1], [1, 0]])
```

修改 DataFrame 索引

- 修改对应的属性即可

```
import pandas as pd


d = {'name': ['Tom', 'Bob', 'Linda'], 'age': [17, 18,
26], 'height': [172, 176, 188]}
df = pd.DataFrame(data=d, index=['p1', 'p2', 'p3'])
print(df)

""" 修改行索引 """
df.index = ['n1', 'n2', 'n3']

""" 修改列索引 """
df.columns = ['names', 'ages', 'heights']

print(df)
```

修改 DataFrame 数据

- 对访问的数据重新赋值，即可修改数据；如果访问数据不存在，则会添加数据

```
import pandas as pd


d = {'name': ['Tom', 'Bob', 'Linda'], 'age': [17, 18,
26], 'height': [172, 176, 188]}
df = pd.DataFrame(data=d, index=['p1', 'p2', 'p3'])
print(df)
```

```
# 修改单列数据
df['height'] = pd.Series([1.72, 1.88, 1.76],
index=df.index)
df['height'] = [1.72, 1.88, 1.76]
df.loc[:, 'height'] = [1.72, 1.88, 1.76]
df.iloc[:, 2:3] = [1.72, 1.88, 1.76]
print(df)

# 修改多列数据
df[['name', 'age']] = pd.DataFrame({'name': ['Bob',
'Tom', 'Jack'], 'age': [19, 22, 27]}, index=df.index)
df[['name', 'age']] = [['Bob', 19], ['Tom', 22],
['Jack', 27]]
df.loc[:, ['name', 'age']] = [['Bob', 19], ['Tom',
22], ['Jack', 27]]
df.iloc[:, :2] = [['Bob', 19], ['Tom', 22], ['Jack',
27]]
print(df)

# 追加单列数据
df['weight'] = pd.Series([65, 75, 60], index=df.index)
df['weight'] = [65, 75, 60]
df.loc[:, 'weight'] = [65, 75, 60]
print(df)

# 追加多列数据
df[['grade', 'address']] = pd.DataFrame({'grade':
['一', '二', '三'], 'address': ['威宁路', '长宁路', '大马
路']}, index=df.index)
df[['grade', 'address']] = [['一', '威宁路'], ['二', '长
宁路'], ['三', '大马路']]
df.loc[:, ['grade', 'address']] = [['一', '威宁路'],
['二', '长宁路'], ['三', '大马路']]
```

```
print(df)

# 修改单行数据
df[1:2] = ['Tony', 23, 178]
df.loc['p2'] = pd.Series(['Tony', 23, 178],
index=df.columns)
df.iloc[1] = ['Tony', 23, 178]
df.iloc[1:2] = ['Tony', 23, 178]
print(df)

# 修改多行数据
df[:2] = [['Jack', 27, 1.76], ['Tony', 19, 1.72]]
df.loc[:'p2'] = [['Jack', 27, 1.76], ['Tony', 19,
1.72]]
df.iloc[[0, 1]] = [['Jack', 27, 1.76], ['Tony', 19,
1.72]]
print(df)

# 追加单行数据
df.loc['p4'] = ['Toby', 23, 178]
print(df)
```

DataFrame 常用属性

属性	描述
T	转置
dtypes	返回每一列的数据类型
shape	返回 DataFrame 的形状
size	返回 DataFrame 中的元素数量
index	返回行索引
columns	返回列索引

属性	描述
axes	以列表形式返回行索引和列索引
values	以 ndarray 数组的形式返回 DataFrame 中的数据

```
import pandas as pd
import numpy as np



d = [['Tom', 17], ['Bob', 18], ['Linda', 26]]
df = pd.DataFrame(data=d, index=['p1', 'p2', 'p3'],
columns=['name', 'age'])
print(df)
print(df.T)
print(df.dtypes)
print(df.shape)
print(df.size)
print(df.index)
print(df.columns)
print(df.axes)
print(df.values)
```

DataFrame 常用方法

DataFrame.isnull() / DataFrame.notnull()

- 检测 DataFrame 中的缺失值

```
import pandas as pd
import numpy as np


d = [[8, np.nan],
     [np.nan, 7],
     [0, 2],
     [np.nan, np.nan]]

df = pd.DataFrame(data=d)
print(df)
print(df.isnull())
print(df.notnull())
```

DataFrame.insert(loc, column, value)

- loc：int，整数列索引，指定插入数据列的位置
- column：新插入的数据列的名字
- value：int, Series, or array-like，插入的数据

```
import pandas as pd


d = {'name': ['Tom', 'Bob', 'Linda'], 'age': [17, 18,
26]}
df = pd.DataFrame(data=d, index=['p1', 'p2', 'p3'])
print(df)

# insert()方法插入新的列
df.insert(2, 'weight', [65, 75, 60])
print(df)
```

DataFrame.reindex(labels=None, axis=0, index=None, columns=None, fill_value=np.NaN)

- labels：要获取数据的列标签或者行标签，传入列表，与axis对应
- axis：轴的方向，0为行，1为列
- index：要获取数据的行索引，传入列表
- columns：要获取数据的列索引，传入列表
- fill_value：填充的缺失值（标量），默认为 np.NaN
- 返回重新索引组成的新的 DataFrame 对象

```
import pandas as pd
import numpy as np


data = np.arange(12).reshape(3, 4)
df = pd.DataFrame(data, index=['n1', 'n2', 'n3'],
columns=['a', 'b', 'c', 'd'])
print(df)

# 重新索引行标签为'n2'的数据行
df2 = df.reindex(labels=['n2'], axis=0)
print(df2)

df2 = df.reindex(index=['n2'])
print(df2)

# 重新索引列标签为'c'的数据行
df2 = df.reindex(labels=['c'], axis=1)
print(df2)

df2 = df.reindex(columns=['c'])
print(df2)

# 分别重新索引行标签为'n2'、'n1'、'n4'的数据行
```

```
df2 = df.reindex(index=['n2', 'n1', 'n4'],
fill_value=np.pi)
print(df2)
```

pd.concat(objs, axis=0, join='outer', ignore_index=False)

- objs：DataFrame对象的序列
- axis：要拼接的轴
- join：外连接（'outer'）保留两个表中的所有信息；内连接（'inner'）只保留共有信息
- ignore_index：如果指定为 True，则索引将变为从0开始递增的整数
- 返回一个新的 DataFrame

```
import pandas as pd


df = pd.DataFrame([[1, 2], [3, 4]], index=['p1',
'p2'], columns=list('AB'))
print(df)

df2 = pd.DataFrame([[5, 6], [7, 8]],
columns=list('AC'))
print(df2)

print(pd.concat([df, df2]))
print(pd.concat([df, df2], join='inner'))
print(pd.concat([df, df2], axis=1))
df2.index = [0, 'p1']  # 修改索引
print(df2)
print(pd.concat([df, df2], axis=1, join='inner'))
```

pd.merge(left, right, how='inner', on=None)

- left：左侧 DataFrame 对象
- right：右侧 DataFrame 对象
- how：要执行的合并类型。'inner'为内连接，取左右两个 DataFrame 的键的交集进行合并；'left'为左连接，以左侧 DataFrame 的键为基准进行合并，如果左侧 DataFrame 中的键在右侧不存在，则用缺失值NaN 填充；'right'为右连接，以右侧 DataFrame 的键为基准进行合并，如果右侧 DataFrame 中的键在左侧不存在，则用缺失值NaN 填充；'outer'为外连接，取左右两个 DataFrame 的键的并集进行合并
- on：指定用于连接的键（即列标签的名字），该键必须同时存在于左右两个 DataFrame 中，如果没有指定，那么将会以两个 DataFrame 的列名交集做为连接键

```
import pandas as pd



d1 = {'name': ['Tom', 'Bob', 'Jack'], 'age': [18, 17,
19], 'weight': [65, 66, 67]}
df1 = pd.DataFrame(data=d1)

d2 = {'name': ['Tom', 'Jack'], 'height': [168, 187],
'weight': [65, 68]}
df2 = pd.DataFrame(data=d2)

print(df1)
print(df2)
print(pd.merge(df1, df2, how='inner', on='name'))
print(pd.merge(df1, df2, how='left', on='name'))
print(pd.merge(df1, df2, how='right', on='name'))
print(pd.merge(df1, df2, how='outer', on='name'))
```

DataFrame.drop(labels=None, axis=0, index=None, columns=None, inplace=False)

- labels：要删除的列标签或者行标签，如果要删除多个，传入列表，与axis对应
- axis：轴的方向，0为行，1为列
- index：要删除的行索引，如果要删除多个，传入列表
- columns：要删除的列索引，如果要删除多个，传入列表
- inplace：inplace=True时，对原数据操作，返回None

```
import pandas as pd


df = pd.DataFrame([[1, 2], [3, 4], [5, 6]], index=
['n1', 'n2', 'n3'], columns=['a','b'])
print(df)

# 删除行索引为'n2'的数据行
print(df.drop(labels='n2', axis=0))
print(df.drop(index='n2'))

# 删除列索引为'b'的数据列
print(df.drop(labels='b', axis=1))
print(df.drop(columns='b'))

# 分别删除行索引为'n2'和'n1'的数据行
print(df.drop(labels=['n2', 'n1'], axis=0))
print(df.drop(index=['n2', 'n1']))

# 分别删除列索引为'a'和'b'的数据列
print(df.drop(labels=['a', 'b'], axis=1))
print(df.drop(columns=['a', 'b']))

# inplace=True时，对原数据操作，返回None
```

```
df.drop(index='n1', inplace=True)
print(df)
```

DataFrame.dropna(axis=0, how='any', thresh=None, subset=None, inplace=False)

- axis：0表示删除包含缺失值的行，1表示删除包含缺失值的列
- how：'any'表示如果存在任何缺失值，则删除该行或列；'all'表示如果所有值都是缺失值，则删除该行或列
- thresh：只保留至少n个非NaN值的行或列，n由该参数指定
- subset：定义要根据哪些列（行）中的缺失值来删除行（列），和axis成行列对应关系
- inplace：如果为 True 表示对原数据操作，返回 None
- 删除缺失值所在的行或列

```
import pandas as pd
import numpy as np


d = {'name': ['Tom', np.nan, 'Bob'], 'age': [np.nan, np.nan, 19], 'height': [177, 182, 179]}
df = pd.DataFrame(data=d)
print(df)

# 删除缺失值所在的行
print(df.dropna())

# 删除缺失值所在的列
print(df.dropna(axis=1))

# 修改数据
df.loc[2, 'age'] = np.nan
print(df)
```

```
# 删除所有值都是缺失值的列
print(df.dropna(axis=1, how='all'))

# 只保留至少2个非NaN值的列
print(df.dropna(axis=1, thresh=2))

# 根据'name'、'height'列中的缺失值来删除行
print(df.dropna(subset=['name', 'height']))

# 根据1、2行中的缺失值来删除列
print(df.dropna(axis=1, subset=[1, 2]))

# 对原数据操作
df.dropna(axis=1, inplace=True)
print(df)
```

DataFrame.fillna(value=None, method=None, axis=None, inplace=False, limit=None)

- value：需要填充的数据
- method：填充方式。'pad'/'ffill' 表示用前一个非缺失值去填充该缺失值；'backfill'/'bfill' 表示用后一个非缺失值填充该缺失值
- axis：指定填充方向
- inplace：如果为 True 表示对原数据操作，返回 None
- limit：限制填充个数

```
import pandas as pd
import numpy as np


df = pd.DataFrame([[np.nan, 2, np.nan, 0],
                   [3, 4, np.nan, 1],
                   [np.nan, np.nan, np.nan, np.nan],
```

```
                      [np.nan, 3, np.nan, 4]],
                      columns=list("ABCD"))

print(df)

# 用标量填充：将所有NaN填充为0
print(df.fillna(0))

# 用字典填充：指定不同列的NaN填充值
dic = {'A': 6, 'B': 7}
print(df.fillna(dic))

# 当使用DataFrame填充时，替换会沿着相同的行列索引进行
np.random.seed(3)
arr = np.random.randint(1, 10, size=(3, 5))
df2 = pd.DataFrame(arr, columns=list("CFAHB"))
print(df2)
print(df.fillna(df2))

# 用前一个非缺失值去填充该缺失值
print(df.fillna(method='ffill'))
# 用后一个非缺失值去填充该缺失值
print(df.fillna(method='bfill'))

# 用前一个非缺失值去填充该缺失值
print(df.fillna(method='ffill', axis=1))
# 用后一个非缺失值去填充该缺失值
print(df.fillna(method='bfill', axis=1))

# 指定'A'列填充为6,'C'列填充7，且限制每列最多填充2个
print(df.fillna({'A': 6, 'C': 7}, limit=2))
```

DataFrame.info(verbose=None, show_counts=None)

- verbose：是否打印完整的摘要，为None时表示打印完整摘要，为False则打印简短摘要
- show_counts：是否显示Non-Null Count，为None时表示显示，为False则不显示
- 打印 DataFrame 的简明摘要

```
import pandas as pd
import numpy as np


df = pd.DataFrame(data={'name': ['Tom', 'Bob',
np.nan], 'age': [18, 19, 17], 'height': [167, 177,
178]}, index=['n1', 'n2', 'n3'])
print(df)
df.info()
df.info(verbose=False)
df.info(show_counts=False)
```

DataFrame.describe(percentiles=None, include=None, exclude=None)

- percentiles：默认值为 [.25, .5, .75]，它返回第 25、第 50 和第 75 个百分位数
- include：包含在结果中的数据类型；默认None表示结果将包括所有数字列；'all'表示包括所有列；'number'表示包括所有数字列；'object'表示包括所有字符列
- exclude：不包含在结果中的数据类型；默认None表示结果不会排除任何列；'number'表示不包括所有数字列；'object'表示不包括所有字符列
- 返回描述性统计

```
import pandas as pd


df = pd.DataFrame(data={'name': ['Tom', 'Bob', 'Bob'],
'age': [18, 19, 17], 'height': [167, 177, 178]},
index=['n1', 'n2', 'n3'])
print(df)
print(df.describe())
print(df.describe(include='all'))
print(df.describe(include='object'))

# 也可以是数据类型的组合
print(df.describe(include=['number', 'object']))
```

DataFrame.count(axis=0)　　返回指定轴的非缺失值的数量
DataFrame.max(axis=0)　　返回指定轴的最大值
DataFrame.min(axis=0)　　返回指定轴的最小值
DataFrame.mean(axis=0)　　返回指定轴的平均值
DataFrame.var(axis=0)　　返回指定轴的方差
DataFrame.std(axis=0)　　返回指定轴的标准差

```
import pandas as pd
import numpy as np


df = pd.DataFrame(data={'name': ['Tom', np.nan,
'Linda'], 'age': [18, 19, 17]}, index=['n1', 'n2',
'n3'])
print(df)
print(df.count())
print(df.count(axis=1))

d = np.random.normal(size=(7, 2))
```

```
df = pd.DataFrame(data=d)
print(df)
print(df.max(axis=0))  # 返回每列最大值
print(df.max(axis=1))  # 返回每行最大值
print(df.min(axis=0))  # 返回每列最小值
print(df.min(axis=1))  # 返回每行最小值
print(df.mean(axis=0))  # 返回每列平均值
print(df.mean(axis=1))  # 返回每行平均值
print(df.var(axis=0))  # 返回每列方差
print(df.var(axis=1))  # 返回每行方差
print(df.std(axis=0))  # 返回每列标准差
print(df.std(axis=1))  # 返回每行标准差
```

DataFrame.sample(n=None, frac=None, replace=False, random_state=None, axis=None)

- n：默认为1，表示要采样的行数或列数，不能和 frac 参数一起使用
- frac：表示要采用的比例，不能和 n 参数一起使用
- replace：表示是否有放回采样
- random_state：随机数种子
- axis：表示采样的方向，默认为0，行采样
- 从指定的轴返回随机样本

```
import pandas as pd



df = pd.DataFrame(data={'name': ['Tom', 'Bob', 'Jack',
'Linda'], 'age': [18, 19, 17, 21], 'height': [167,
177, 178, 188]}, index=['n1', 'n2', 'n3', 'n4'])
print(df)

# 默认n=1，随机采样一行数据
```

```
print(df.sample())

# 随机采样75%的数据，即这里即3行
print(df.sample(frac=0.75))

# 随机采样2行数据
print(df.sample(n=2))

# 随机有放回采样2行数据(有可能会重复采样)
print(df.sample(n=2, replace=True))

# 随机采样2列数据
print(df.sample(n=2, axis=1))

# 随机采样2行数据，设置随机数种子seed为3
print(df.sample(n=2, random_state=3))
```

DataFrame.drop_duplicates(subset=None, keep='first', inplace=False)

- subset：表示要进行去重的列名，默认为 None，表示所有列
- keep：保留哪些副本。'first'表示只保留第一次出现的重复项，删除其余重复项；'last '表示只保留最后一次出现的重复项；False 则表示删除所有重复项
- inplace：False 表示删除重复项后返回一个副本；Ture 表示直接在原数据上删除重复项
- 返回去重（删除重复行）之后的 DataFrame

```
import pandas as pd


d = {'A': [1, 3, 3, 1], 'B':[0, 2, 5, 0],
    'C': [4, 0, 4, 4], 'D':[1, 0, 0, 1]}
```

```
df = pd.DataFrame(data=d)
print(df)

# 第一行和第四行重复，删除第4行
print(df.drop_duplicates())

# 第一行和第四行重复，删除第1行
print(df.drop_duplicates(keep='last'))

# 第一行和第四行重复，两行都删除
print(df.drop_duplicates(keep=False))

# 指定columns为'A'和'D'的两列去重
# 第二行和第三行重复，保留第三行
# 第一行和第四行重复，保留第四行
print(df.drop_duplicates(subset=['A', 'D'],
keep='last'))

# 直接在原数据上删除重复项
df.drop_duplicates(subset=['A', 'D'], keep='last',
inplace=True)
print(df)
```

DataFrame.sort_values(by, axis=0, ascending=True, inplace=False, na_position='last')

- by：要排序的名称或名称列表

  如果 axis=0 或 'index'，by可指定列标签

  如果 axis=1 或 'columns'，by可指定行标签
- axis：要排序的轴，可选择 0 或 'index', 1 或 'columns'
- ascending：False 则为降序；如果这是一个 bool 列表，则必须匹配 by 的长度

- inplace：是否原地操作
- na_position：设置缺失值的排序位置，'first'表示开头，'last'表示结尾

```
import pandas as pd
import numpy as np


df = pd.DataFrame({'col1': [4, 1, 2, np.nan, 5, 2],
                   'col2': [2, 1, 9, 8, 7, 6],
                   'col3': [0, 1, 9, 4, 2, 3],
                   'col4': ['a', 'B', 'c', 'D', 'e',
1]})


print(df)
print(df.sort_values(by=['col1']))
print(df.sort_values(by='col1'))
print(df.sort_values(by=['col1', 'col2']))
print(df.sort_values(by=5, axis=1))
print(df.sort_values(by=5, axis=1, ascending=False))
print(df.sort_values(['col1', 'col2'], ascending=
[True, False]))
print(df.sort_values(by='col1', na_position='first'))
df.sort_values(by='col1', inplace=True)
print(df)
```

DataFrame.apply(func, axis=0)

- func：应用于每一个列或行的函数
- axis：0 or 'index'表示函数处理的是每一列；1 or 'columns'表示函数处理的是每一行
- 沿着给定的 DataFrame 轴应用 func 的结果

```
import pandas as pd
import numpy as np


d = [[1, 2, 0], [4, 1, 9], [2, 5, 7], [4, 3, 6]]
df = pd.DataFrame(d, columns=['A', 'B', 'C'])
print(df)
print(df.apply(np.sum))
print(df.apply(np.sum, axis=1))
```

DataFrame.groupby(by=None, as_index=True, sort=True, dropna=True)

- by：指定根据哪个或者哪些标签分组
- as_index：对于聚合操作的输出结果，默认将分组列的值作为索引，如果将 as_index 设置为 False，可以重置索引（0, 1, 2...）
- sort：结果按分组标签的值升序排列，设置为False则不排序
- dropna：默认为 True 时，分组标签那列的 NaN 在分组结果中不保留，设置为 False，可以保留 NaN 分组
- 返回一个包含分组信息的 DataFrameGroupBy 对象

```
import pandas as pd
import numpy as np


d = {
    'company': ['A', 'B', 'A', 'C', 'C', 'B', 'C',
'A'],
    'salary': [8, 15, 10, 15, np.nan, 28, 30, 15],
    'age': [26, 29, 26, 30, 50, 30, 30, 35]
    }

df = pd.DataFrame(data=d)
print(df)
```

```python
# 根据'company'列的数据对行分组，返回DataFrameGroupBy的实例对象
df_gb = df.groupby(by='company', as_index=False)

# 该实例对象是iterable，迭代操作可以得到各个分组
for g, data in df_gb:
    print(g)
    print(data)

""" DataFrameGroupBy相关属性 """
print(df_gb.ngroups)  # 分成了几组
print(df_gb.groups)  # 各个分组的index
print(df_gb.indices)  # 各个分组的index

""" DataFrameGroupBy相关方法 """
# 获取指定组的数据
print(df_gb.get_group('A'))
print(df_gb.get_group('B'))
print(df_gb.get_group('C'))

# 聚合操作(对各个组的数据分别操作)
print(df_gb.agg('mean'))
print(df_gb.agg(np.mean))
print(df_gb.agg('max'))
print(df_gb.agg('min'))
print(df_gb.agg('sum'))
print(df_gb.agg('median'))
print(df_gb.agg('std'))
print(df_gb.agg('var'))
print(df_gb.agg('count'))

# 变换操作(在聚合操作的结果之上，还将值变换到分组前的对应位置上)
```

```
print(df_gb.transform('mean'))
print(df_gb.transform(np.mean))

# 新增两列数据
df[['avg_salary', 'avg_age']] =
df_gb.transform('mean')
print(df)

# df_gb = df.groupby(by='salary', sort=False)
# for g, data in df_gb:
#     print(g)
#     print(data)
#
# df_gb = df.groupby(by='salary', dropna=False)
# for g, data in df_gb:
#     print(g)
#     print(data)
#
# # 也可以根据多列数据对行分组
# df_gb = df.groupby(by=['age', 'company'])
# for g, data in df_gb:
#     print(g)
#     print(data)
```

DataFrame 的运算

DataFrame 保留了 NumPy 中的数组运算，且 DataFrame 进行数组运算的时候，索引与值之间的映射关系不会发生改变。在进行 DataFrame 和 DataFrame 的运算时，把两个 DataFrame 中行索引名和列索引名一样的值进行运算，其他不一样的做并集且对应的值为NaN

```
import pandas as pd
import numpy as np



d = np.arange(9).reshape((3, 3))
df1 = pd.DataFrame(data=d, columns=list('abc'), index=
['n1', 'n2', 'n3'])
print(df1)

print(df1 + 1)
print(df1 - 1)
print(df1 * 2)
print(df1 / 2)

d = np.arange(16).reshape((4, 4))
df2 = pd.DataFrame(data=d, columns=list('dacf'),index=
['n1', 'n2', 'n3', 'n4'])
print(df2)

print(df1 + df2)
print(df1 - df2)
print(df1 * df2)
print(df1 / df2)
```

Pandas 文件读写

CSV文件读写

```
import pandas as pd
import numpy as np


df = pd.read_csv('./test01.csv')
print(df)

# sep参数默认为逗号(test02.csv文件是用分号分隔)
df = pd.read_csv('./test02.csv', sep=';')
print(df)

# header参数默认自行推断, 会把第一行数据作为列索引(表头)
# 如果不想使用数据为列索引, 可设置为None, 那么列索引就会是(0,
1...)
df = pd.read_csv('./test03.csv', sep=';', header=None)
print(df)

# header=2, 指定第3行数据作为列索引(表头), 之后的行才为数据
df = pd.read_csv('./test03.csv', sep=';', header=2)
print(df)

# names参数可以指定列索引, 如果指定names, 则header推断为
None
df = pd.read_csv('./test02.csv', sep=';', names=
['name', 'age', 'height'])
print(df)

# 读取大文件片段
# nrows参数用来读取指定行数的数据：这里读取前两行数据(header先
推断再读取)
df = pd.read_csv('./test01.csv', nrows=2)
print(df)
```

```
# skiprows参数用来指定需要跳过的行(先跳过，header再推断)
# 当skiprows为整数时，表示跳过对应的前几行：这里跳过前两行
df = pd.read_csv('./test01.csv', skiprows=2)
print(df)
# 当skiprows为索引时，表示跳过对应的索引行：这里跳过第1行和第3
行
df = pd.read_csv('./test01.csv', skiprows=[0, 2])
print(df)

# usecols参数用来读取指定列的数据：这里读取第1列和第3列
df = pd.read_csv('./test01.csv', usecols=[0, 2])
print(df)

# chunksize参数指定时，read_csv会返回TextFileReader对象
# TextFileReader对象是个迭代器，可以按照chunksize迭代
obj = pd.read_csv('./test01.csv', chunksize=2)
for i in obj:
    print(i)
```

```
import pandas as pd


d = {
    '名字': ['张三', '李四', '王五', '赵六', '孙七'],
    '年龄': [18, 19, 20, 22, 17],
    '身高': [188, 178, 189, 175, 177]
    }
df = pd.DataFrame(data=d)
print(df)

# 把DataFrame写入csv文件
# sep参数默认为逗号，所以文件中分隔符为逗号
```

```
# index参数默认为True, 所以行索引也被写入了文件
# header参数默认为True, 所以列索引也被写入了文件
df.to_csv('./test04.csv')

# 可以给sep参数指定其他的分隔符(分隔符必须是一个字符)
df.to_csv('./test05.csv', sep=';')

# 如果不想把行索引写入文件可以把index参数指定为False
df.to_csv('./test06.csv', index=False)

# 如果不想把列索引写入文件可以把header参数指定为False
df.to_csv('./test07.csv', header=False)
```

EXCEL文件读写

```
import pandas as pd



d = {
    '名字': ['张三', '李四', '王五', '赵六', '孙七'],
    '年龄': [18, 19, 20, 22, 17],
    '身高': [188, 178, 189, 175, 177]
    }
df = pd.DataFrame(data=d)
print(df)

# 把DataFrame写入excel文件
# index参数默认为True, 所以行索引也被写入了文件
# header参数默认为True, 所以列索引也被写入了文件
df.to_excel('./test08.xlsx')
```

```
# 如果不想把行索引写入文件可以把index参数指定为False
df.to_excel('./test09.xlsx', index=False)

# 如果不想把列索引写入文件可以把header参数指定为False
df.to_excel('./test10.xlsx', header=False)


# 把DataFrame写入excel文件
writer = pd.ExcelWriter('./test11.xlsx')
# 写入工作表1
df.to_excel(writer, sheet_name='工作表1', index=False)
# 写入工作表2
df.iloc[:, :2].to_excel(writer, sheet_name='工作表2',
index=False)
writer.close()

# with语句更优雅
with pd.ExcelWriter('./test11.xlsx') as writer:
    df.to_excel(writer, sheet_name='工作表1',
index=False)
    df.iloc[:, :2].to_excel(writer, sheet_name='工作表
2', index=False)
```

```
import pandas as pd


# header参数默认为0, 会把第一行作为列索引(表头)
df = pd.read_excel('./test11.xlsx')
print(df)

# 如果不想使用数据为列索引, 可设置为None, 那么列索引就会是(0,
1...)
```

```
df = pd.read_excel('./test11.xlsx', header=None)
print(df)

# header=2, 指定第3行数据作为列索引(表头), 之后的行才为数据
df = pd.read_excel('./test11.xlsx', header=2)
print(df)

# names参数可以指定列索引(表头)
# 因为header为默认值0, 第一行会被names参数指定的值覆盖掉
df = pd.read_excel('./test11.xlsx', names=['name',
'age', 'height'])
print(df)

# 因为header为None, 第一行仍会当作数据
df = pd.read_excel('./test11.xlsx', header=None,
names=['name', 'age', 'height'])
print(df)

# sheet_name指定要读取的工作表
# 如果为整数, 则为工作表的索引; 默认为0, 表示读取第一个工作表
df = pd.read_excel('./test11.xlsx', sheet_name=1)
print(df)

# 如果为字符串, 则为工作表的名称
df = pd.read_excel('./test11.xlsx', sheet_name='工作表
2')
print(df)

# 如果想要读取多个工作表, 可以指定为列表
df = pd.read_excel('./test11.xlsx', sheet_name=[0, '工
作表2'])
print(df)
```

```python
# 读取大文件片段
df = pd.read_excel('./test11.xlsx', nrows=2)
print(df)

df = pd.read_excel('./test11.xlsx', skiprows=2)
print(df)

df = pd.read_excel('./test11.xlsx', skiprows=[0, 2])
print(df)

df = pd.read_excel('./test11.xlsx', usecols=[0, 2])
print(df)
```